ĐẠI HỌC BÁCH KHOA – ĐẠI HỌC ĐÀ NẴNG

NGHIÊN CỨU · ĐÁNH GIÁ · TỐI ƯU

Hệ thống số Posit

và các phương pháp tối ưu cho mô hình AI hiệu năng cao

Nhóm thực hiện: [Họ tên SV 1] · [Họ tên SV 2]
GVHD: [Tên giảng viên] · Học phần: Xử lý dữ liệu

Đà Nẵng, 10/2026

OVERVIEW

Nội dung trình bày

01 Đặt vấn đề

02 Lịch sử & cấu trúc posit

03 Đặc tính của posit

04 Tổng quan nghiên cứu

05 Điểm mạnh – điểm yếu

06 Bốn hướng tối ưu

07 Thiết lập thực nghiệm

08 Kết quả thực nghiệm

09 Kết luận & hướng phát triển

10 Hỏi đáp

PROBLEM STATEMENT

Đặt vấn đề

01

Mô hình AI ngày càng “đắt”

GPT-3 có 175 tỉ tham số. Đọc SRAM 16-bit tốn ≈ 80× năng lượng một phép nhân–cộng; nhân FP32 tốn ≈ 4× FP16 → **giảm số bit mỗi số** là đòn bẩy lớn nhất.

02

IEEE 754 không sinh ra cho AI

Dải 80 bậc độ lớn là thừa · độ chính xác “phẳng” ở mọi độ lớn · FP32 có 16,7 triệu mẫu bit NaN và hai số 0 · làm tròn sau mỗi phép tính.

Nguồn: [11] tr.1 · [33] tr.2 · [06] tr.1 · [03] tr.2 · [21] tr.2

RESEARCH OBJECTIVES

Mục tiêu & phương pháp

Q1	Posit là gì, khác IEEE 754 ở đâu?
Q2	Bằng chứng nào cho posit khi suy luận và huấn luyện — kể cả bằng chứng ngược chiều?
Q3	Các phương pháp tối ưu mới nhất (2019–2026)?
Q4	Nhóm có tự tái hiện được các kết luận chính không?

21 bài báo (2018–2026)

40 khẳng định gắn nguồn + trang

5 thí nghiệm tự chạy

THEORETICAL FRAMEWORK

Lịch sử phát triển của posit

2015–16
Unum I & II
Độ dài thay đổi, bảng tra — khó làm phần cứng

2017
Posit (Unum III)
Gustafson & Yonemoto: thay thế trực tiếp IEEE 754

2018–19
Vào học sâu
Lưu trọng số, FPGA, huấn luyện đầu tiên

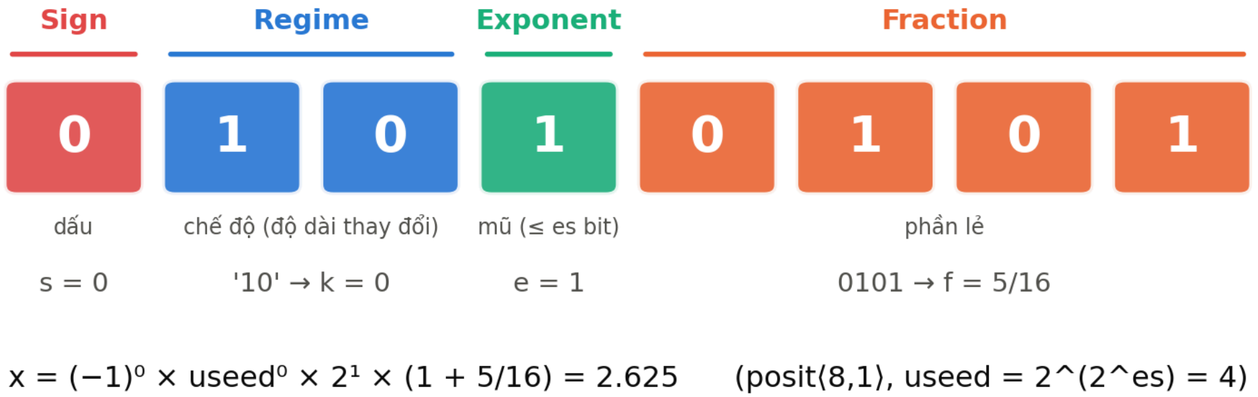
2022
Posit Standard
es = 2 cố định, quire 16n bit

2024–26
Biến thể mới
Logarithmic Posit, MAC đa độ chính xác

Phần cứng: FPGA (Deep Positron, 2019) → lõi RISC-V (POSAR, 2021) → công nghiệp (Kalray, 2022)

Nguồn: [S1] Gustafson & Yonemoto 2017 · [03] tr.2 · [05] tr.2 · [44] · [18] tr.2 · [35] · [48]

Cấu trúc một số posit



Regime độ dài thay đổi: số càng gần 1 → regime càng ngắn → còn nhiều bit phần lẻ

Chỉ **2** giá trị đặc biệt: 0 và NaR

2,625 là posit 8-bit gần số e nhất

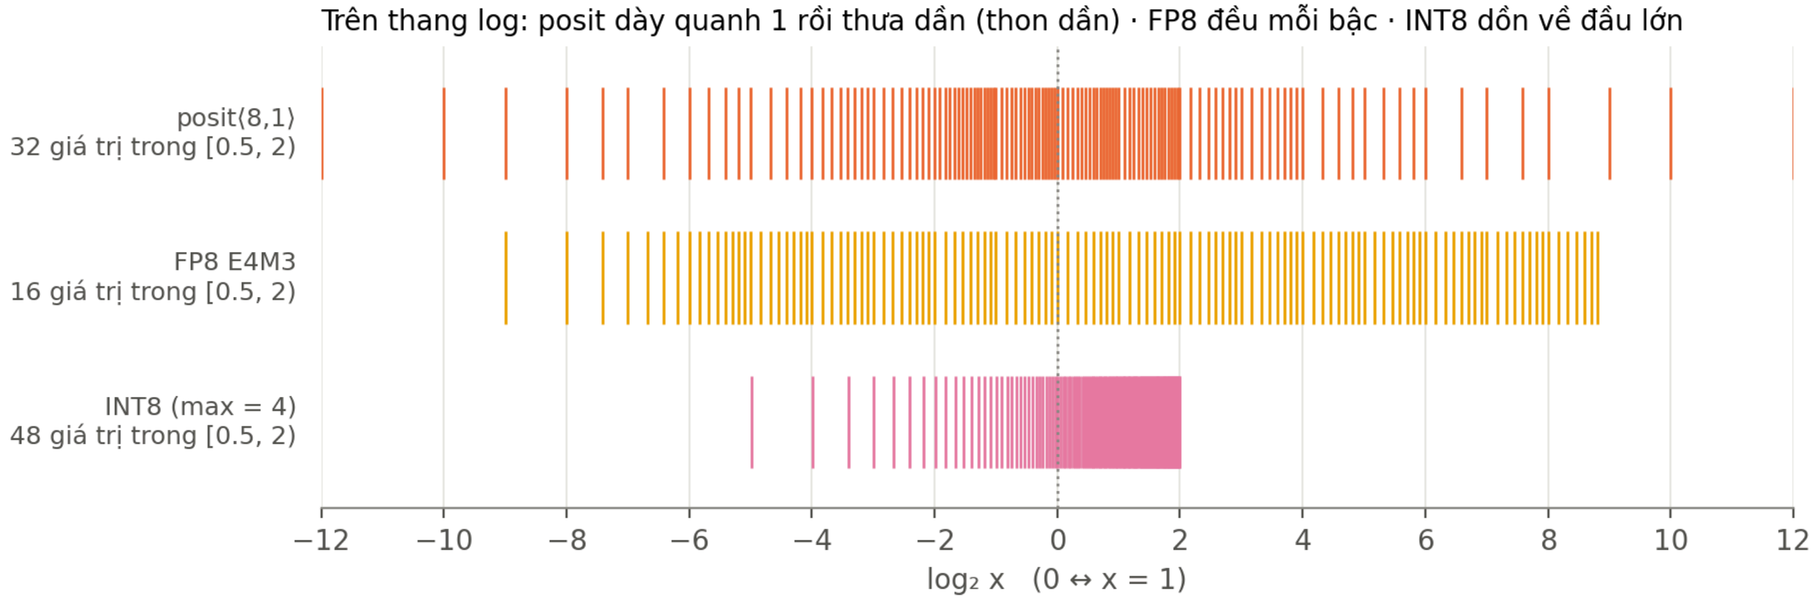
$$x = (-1)^s \times useed^k \times 2^e \times (1 + f),\ useed = 2^{(2^{es})}$$

Nguồn: [03] tr.2 · [06] tr.1 · [44] tr.9 · hình: nhóm vẽ, giá trị kiểm chứng bằng bộ giải mã

TAPERED PRECISION

Độ chính xác thon dần

Trong [0,5; 2): posit 8-bit có **32** giá trị, FP8 chỉ **16**. Activation của mạng ≈ 1 → đúng vùng chính xác nhất; trọng số ≈ 0,04 → lệch, cần co giãn theo lớp.



KEY PROPERTIES

Bốn đặc tính cần nhớ

01

Quire — cộng dồn chính xác

Chỉ làm tròn 1 lần ở cuối tích vô hướng. Chuẩn cũ $n^2/2$ bit (posit8: 32 bit); chuẩn 2022: 16n bit.

02

Tham số es — đánh đổi

es nhỏ: chính xác quanh 1 nhưng dải hẹp. ResNet-50 với posit(8,0) sụp (−76%), với posit(8,1) chỉ −0,87%.

03

Không tràn

Số quá lớn giữ ở maxpos, quá nhỏ giữ ở minpos — không bao giờ thành ∞ hay 0.

04

es = 0: sigmoid bằng thao tác bit

$\sigma(x) \approx (X \text{ XOR } 2^{n-1}) >> 2$ — chỉ 2 phép toán; sai số tối đa ≈ 0,06 (nhóm kiểm chứng).

Nguồn: [43] tr.3, tr.5 · [11] tr.2 · [12] tr.2 · [05] tr.7 · Thí nghiệm E của nhóm

Tổng quan nghiên cứu — suy luận

Năm	Nghiên cứu	Kết quả chính
2018	Lưu trọng số CNN [01]	Posit 5–7 bit = fixed 7–11 bit, tiết kiệm 22–36% bộ nhớ
2018	ResNet-50 ImageNet [43]	posit(8,1) + quire: −0,87% Top-1 · posit(8,0): sụp (−76%)
2019	Deep Positron [03] [04]	MLP trên FPGA: posit 8-bit ≥ float, fixed 8-bit
2019	Cheetah, CIFAR-10 [07]	5 bit: posit 41,3% · float 12,8% · fixed 9,7%
2022	Kalray, ImageNet [18]	es = 0 làm VGG16 sụp (10,2%) · es = 1, 2 giữ gần nguyên

Kết luận: 8-bit (es ≥ 1) + cộng dồn chính xác ≈ FP32 · lợi thế rõ nhất ở ≤ 6 bit · es = 0 sụp ở mạng lớn

Nguồn: [01] tr.3 · [43] tr.5 · [03] tr.5 · [04] tr.6 · [07] tr.7 · [18] tr.5

LITERATURE REVIEW · TRAINING

Tổng quan nghiên cứu — huấn luyện

Năm	Nghiên cứu	Kết quả chính
2019	MLP, MNIST [06]	Posit-16: 96,5% · Float-16 thuần: 90,6%
2019	ResNet-18 ImageNet [08]	Posit-16: 71,09% = FP32 71,02% (warm-up + co giãn theo lớp)
2021	LeNet-5 Fashion [11]	posit(8,0) thuần: **10%** · hỗn hợp O12L10: 90,25% (FP32 90,42%)
2021	7 mạng GAN [40]	posit 8-bit + co giãn ≈ FP16 · FP8 thất bại

Kết luận: 16-bit đủ để huấn luyện · 8-bit thuần thất bại → cần độ chính xác hỗn hợp (optimizer 12-bit, loss 10-bit)

Nguồn: [06] tr.2 · [08] tr.4 · [11] tr.3–4 · [40] tr.5

STRENGTHS

Điểm mạnh của posit

6 bit

độ chính xác tối đa của posit 8-bit — float 8-bit chỉ 5 bit [42]

14,45

bậc dải động của posit⟨8,2⟩ — rộng hơn cả FP16 16-bit (12,04) [18]

> 95%

trường hợp lật bit mà posit32 sai ít hơn float32 [46]

Chỉ 2 giá trị đặc biệt: 0 và NaR

Quire: cộng dồn chính xác

Sigmoid bằng 2 phép toán bit

Nguồn: [42] tr.5 · [18] tr.4 (nhóm tính lại khớp) · [46] tr.4 · [43] tr.3 · [05] tr.7

WEAKNESSES & GAPS

Điểm yếu & khoảng trống

Chưa có phần cứng phổ biến

Phải mô phỏng: huấn luyện CifarNet mất ~10 ngày [36]

Giải mã regime tốn mạch

Trên RISC-V thật, posit32 tốn +30% LUT, +27% DSP — lợi ích “not spectacular” [44]

Ít bit dễ sụp

es = 0 hoặc ≤ 5 bit: còn 0,1–10% [43] [12]; huấn luyện 8-bit thuần thất bại [11]

Quire rất đắt

~10× diện tích, ~8× độ trễ so với posit không quire [44]

Khoảng trống: LLM/Transformer · chip thật đo năng lượng · so sánh công bằng với INT/FP8 có hiệu chỉnh

Nguồn: [36] tr.4 · [44] tr.1, tr.3, tr.11 · [43] tr.5 · [12] tr.7 · [11] tr.3

EVALUATION

Bảng đánh giá tổng hợp

Tiêu chí	FP32	FP16/BF16	INT8	FP8	Posit 8	Posit 16
Suy luận	Cao	Cao	Cao*	Khá	Cao*	Cao
Huấn luyện	Cao	Cao*	Thấp	Khá	Thấp*	Cao
Tiết kiệm bộ nhớ	Thấp	Khá	Cao	Cao	Cao	Khá
Mạch rẻ (cùng bit)	—	Khá	Cao	Cao	Khá	Khá
Phần cứng sẵn có	Cao	Cao	Cao	Khá	Thấp	Thấp

* cần kèm kỹ thuật: hiệu chỉnh (INT8), loss scaling (FP16), es phù hợp + quire (posit 8 suy luận), độ chính xác hỗn hợp (posit 8 huấn luyện). Đánh giá định tính của nhóm từ các bằng chứng đã trình bày.

Tổng hợp từ [03] [05] [06] [08] [11] [18] [40] [43] [44] — chi tiết: báo cáo Word, Mục 5.3

PHẦN IV · OPTIMIZATION

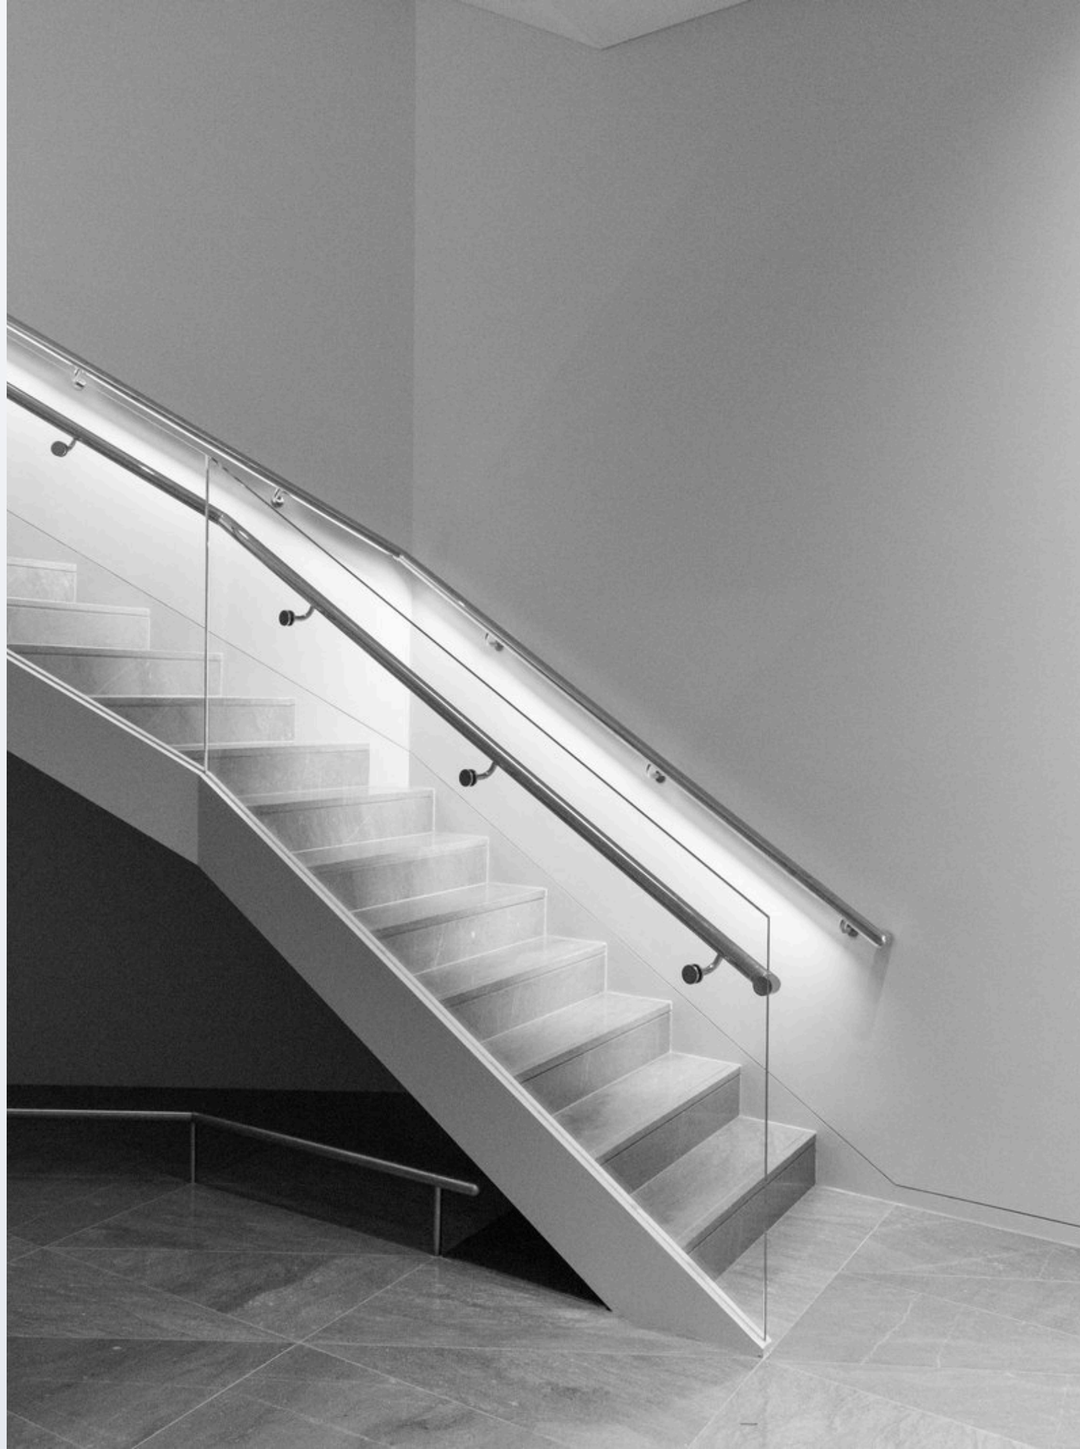
Bốn hướng tối ưu posit cho AI

1 Phần cứng tính toán

2 Định dạng & lượng tử hóa thích ứng

3 Tích hợp vào hệ thống sẵn có

4 Kỹ thuật huấn luyện



HƯỚNG 1 · HARDWARE

Tối ưu phần cứng tính toán

PLAM · NHÂN XẤP XỈ LOG [36]

−82%

công suất bộ nhân 32-bit (−73% diện tích). $\log_2(1 + f) \approx f \rightarrow$ **phép nhân thành phép cộng**; sai số ≤ 11,1%.

QUIRE NHỎ [27]

−43%

diện tích MAC: quire 15 bit thay cho 63 bit mà ResNet-9 vẫn giữ độ chính xác.

SPADE · SIMD [48]

4×

MAC/W ở chế độ 8-bit: một mạch chạy 1×P32, 2×P16 hoặc 4×P8 (28 nm, 6,1 mW).

Nguồn: [36] tr.1, tr.4–5 (−72,86% / −81,79%) · [27] tr.3 · [48] tr.4 (preprint 2026)

HƯỚNG 2 · ADAPTIVE FORMATS

Định dạng & lượng tử hóa thích ứng

Co giãn lũy thừa 2 theo lớp — chỉ là cộng vào số mũ: MNIST 5-bit, posit es = 0 tăng từ 91,05% lên 98,28% [07]

2020 · [33]

Adaptive Posit

Thêm rs, Kb để chỉnh dải theo lớp. ResNet-50 5-bit: 51,5% so với 15,2%

2021 · [12]

ALPS

Chọn tham số bằng SQNR + kurtosis, không cần dò. Hơn posit 14% (TB)

2024 · [35] DAC

Logarithmic Posit

Posit + miền log, mixed 2/4/8-bit. CNN ImageNet giảm < 1%, 2× TOPS/mm²

Nguồn: [07] tr.8 · [08] tr.4 · [33] tr.7 · [12] tr.6–7 · [35] tr.5 (ViT-B vẫn −4,39 điểm)

Tích hợp hệ thống & kỹ thuật huấn luyện

03

Tích hợp vào phần cứng sẵn có

- Lưu Posit8, giải nén ra FP16 cho tensor core (Kalray) [18]
- Lưu 8-bit, tính 16-bit: 68,47% so với 68,15% FP32 [44]
- Vector hóa trên RISC-V ngang ARM SVE [21]

04

Kỹ thuật huấn luyện

- Warm-up bằng FP32 1–5 epoch đầu [08]
- es = 1 cho trọng số, es = 2 cho gradient [08]
- Optimizer 12-bit, loss 10-bit (O12L10) [11]
- Loss scaling về vùng 2^{-4} … 2^{4} [40]

Nguồn: [18] tr.2, tr.10 · [44] tr.9 · [21] tr.8 · [08] tr.3–4 · [11] tr.4 · [40] tr.4

PHẦN V · METHODOLOGY

Thiết lập thực nghiệm của nhóm

01

Mô hình & dữ liệu

LeNet-5 (61 706 tham số) · Fashion-MNIST · PyTorch trên Apple M2. FP32 gốc: 90,94 ± 0,31% (3 lần huấn luyện)

02

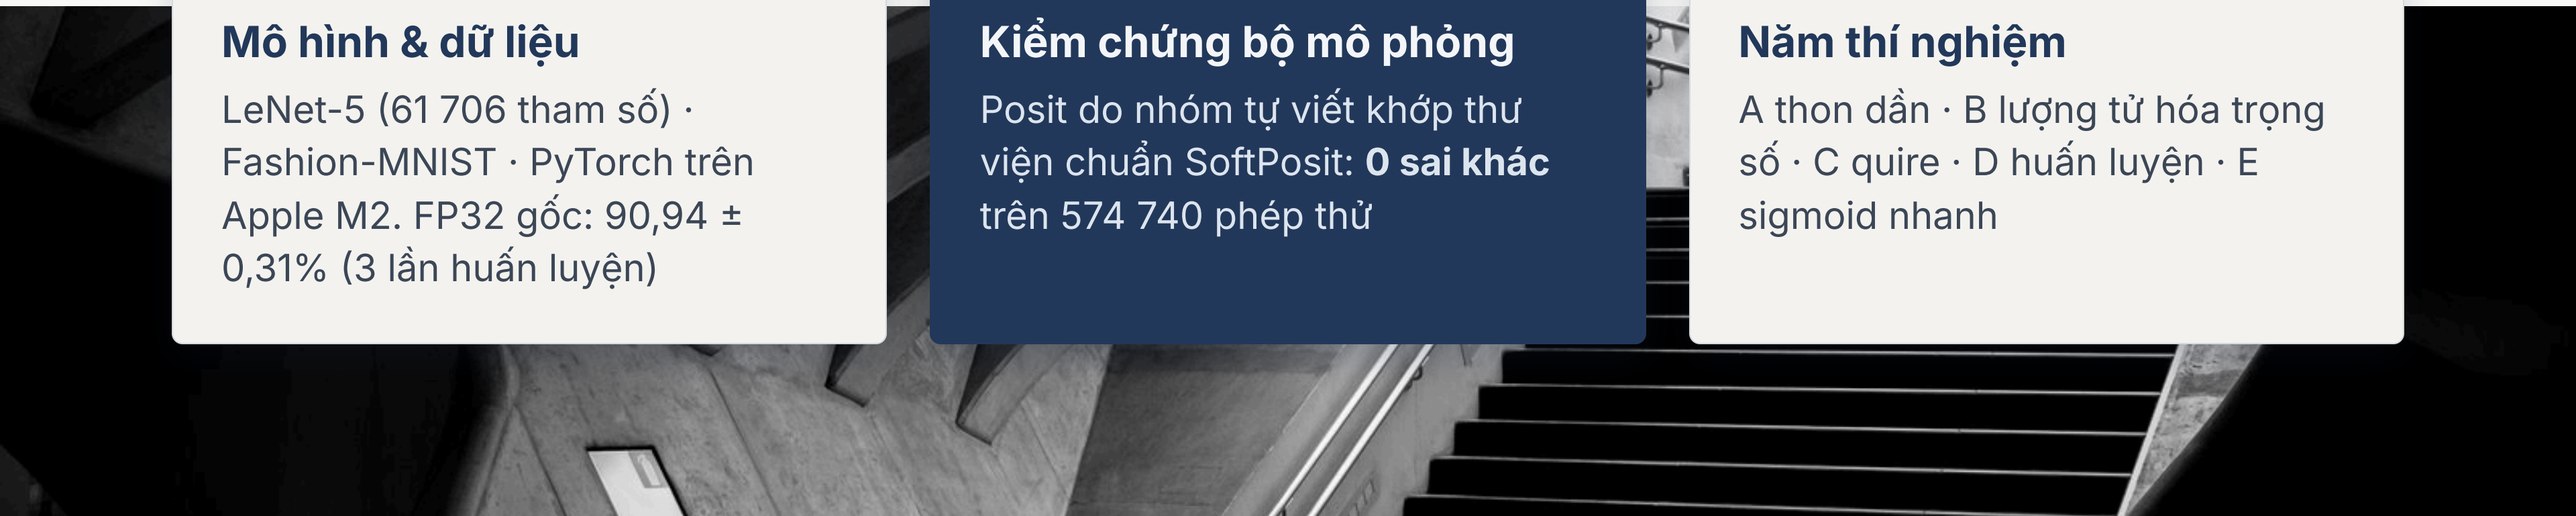
Kiểm chứng bộ mô phỏng

Posit do nhóm tự viết khớp thư viện chuẩn SoftPosit: **0 sai khác** trên 574 740 phép thử

03

Năm thí nghiệm

A thon dần · B lượng tử hóa trọng số · C quire · D huấn luyện · E sigmoid nhanh



RESULTS · THÍ NGHIỆM B

Lượng tử hóa trọng số: posit thắng khi nào?

≈ FP32

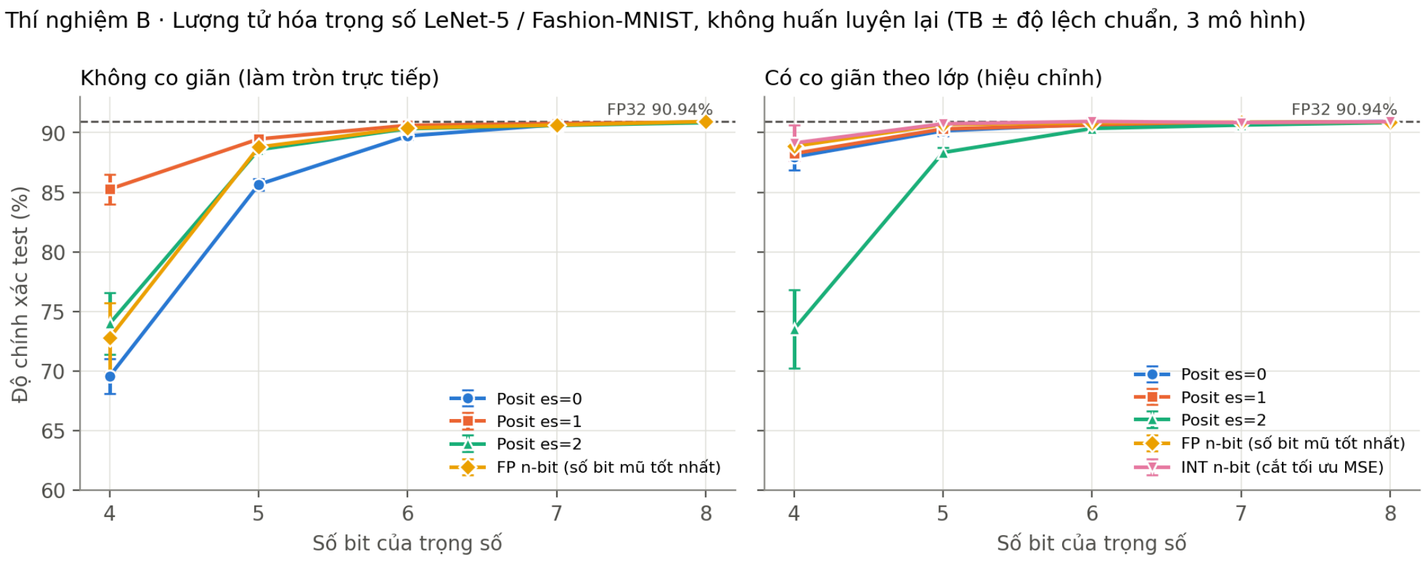
ở 8 bit, mọi định dạng (90,6–90,9%)

85,3%

posit⟨4,1⟩ không hiệu chỉnh — FP4 chỉ 20,2%

89,1%

INT4 khi có co giãn — bắt kịp posit (88,3%)



TB 3 mô hình, 10 000 ảnh test · đối chiếu [07] tr.7–8 (rounding vs linear quantization), [12] tr.6

RESULTS · THÍ NGHIỆM C

Quire có thật sự cần thiết?

TÍCH VÔ HƯỚNG 4 096 PHẦN TỬ · POSIT⟨8,1⟩

1,4%
sai số khi có quire

59,6%
sai số khi làm tròn mỗi bước (FMA)

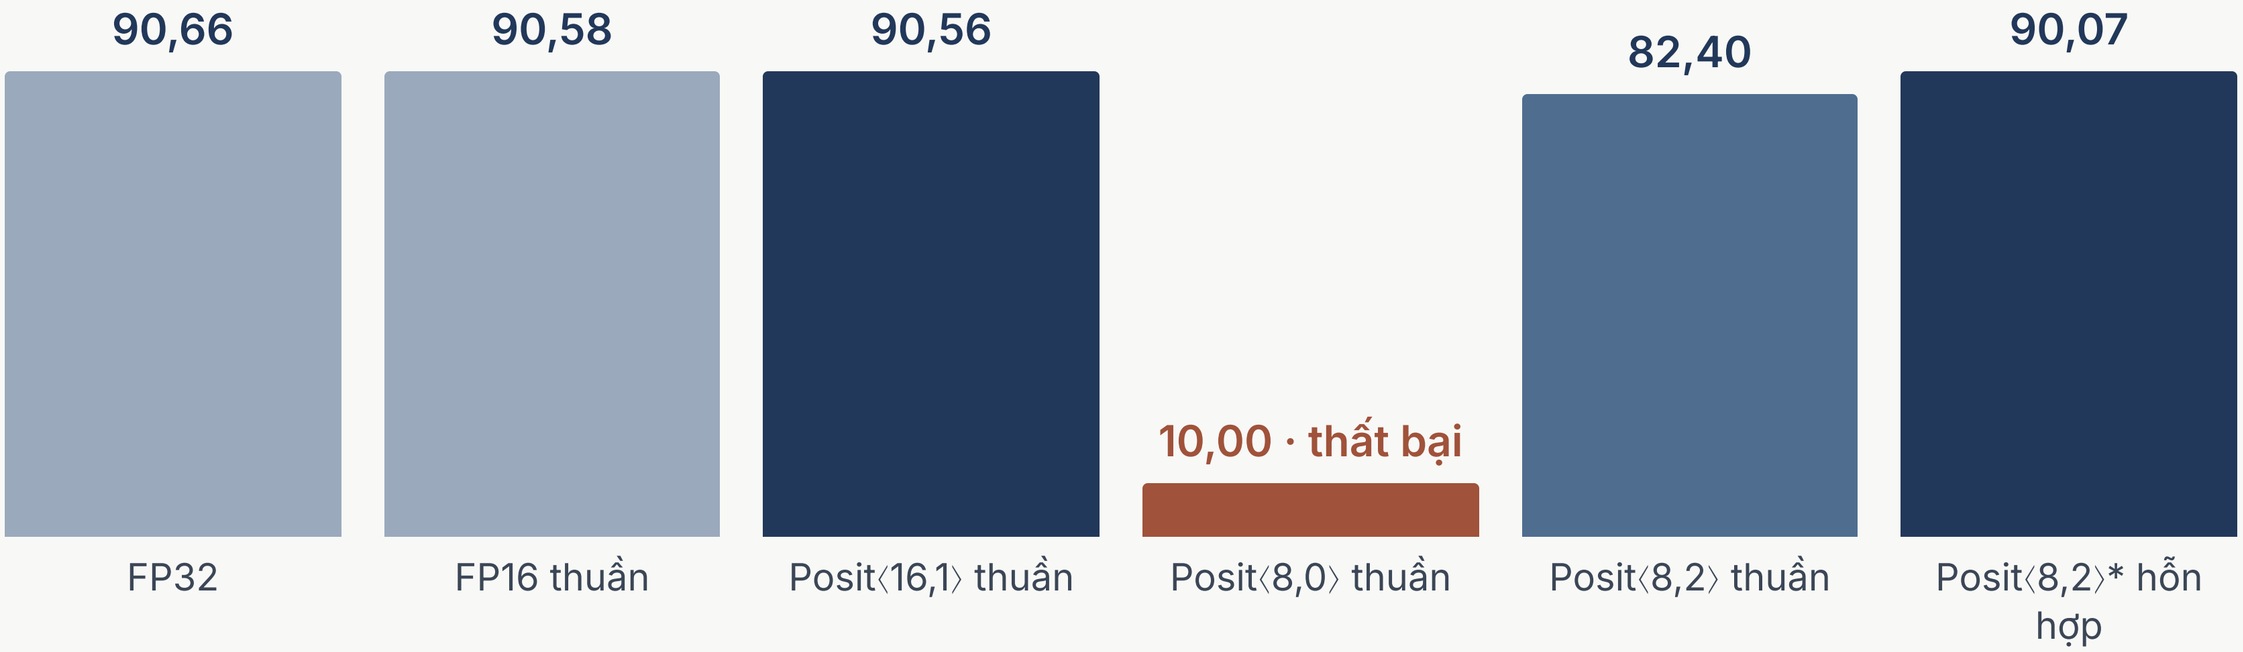
W + A 8-bit	Quire	FMA	Giảm
posit⟨8,0⟩	90,89	88,83	−2,06
posit⟨8,1⟩	90,89	89,80	−1,09
posit⟨8,2⟩	90,87	89,45	−1,42
FP8 E4M3	90,84	89,48	−1,36
posit⟨16,1⟩	90,93	90,94	0

Độ chính xác (%) LeNet-5, TB 3 mô hình · FP32: 90,94 · INT8 cộng dồn int32 (vốn chính xác): 90,98

TB các mô hình gốc, 10 000 ảnh test · đối chiếu [43] tr.3 (c + ab = c), [03] tr.3, [27]

RESULTS · THÍ NGHIỆM D

Huấn luyện bằng posit 8-bit



Độ chính xác test (%) sau 10 epoch · LeNet-5, Fashion-MNIST · * O12L10 của [11]: tính 8-bit, loss 10-bit, optimizer & trọng số chính 12-bit

Đối chiếu [11] tr.3–4: posit(8,0) 10,00% · (8,2)+quire 19,39% · O12L10 90,25% (FP32 90,42%)

CONCLUSION

Kết luận

Posit là ý tưởng tốt nhưng chưa thay ngay được FP16 hay INT8.

01

Thon dần + quire là cốt lõi

Lợi thế thật ở ≤ 6 bit và khi không hiệu chỉnh; ở 8 bit, INT/FP có hiệu chỉnh bắt kịp.

02

8-bit suy luận ≈ FP32, huấn luyện thì chưa

Suy luận cần es ≥ 1 và quire; huấn luyện cần 16-bit hoặc độ chính xác hỗn hợp.

03

Rào cản: phần cứng & hệ sinh thái

Xu hướng mới là định dạng lai lấy cảm hứng từ posit (Logarithmic Posit, MAC SIMD).

RECOMMENDATIONS

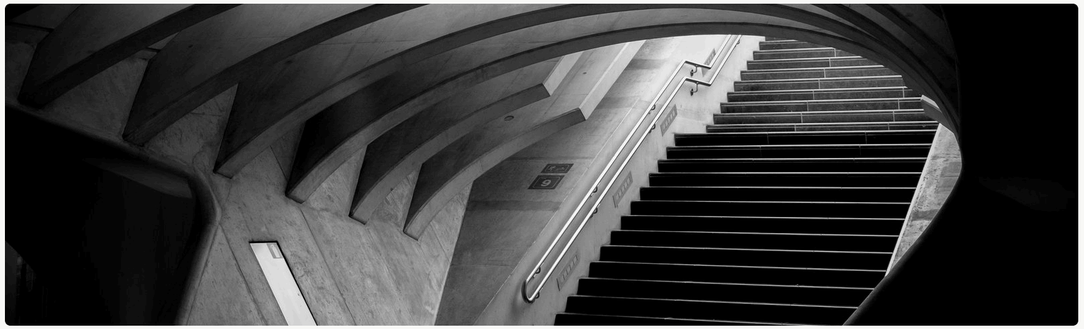
Hướng phát triển cuối kỳ



01

Mở rộng thí nghiệm

ResNet-18 trên CIFAR-10; áp dụng Posit Standard 2022 (es = 2); thử nhân xấp xỉ PLAM ở 8 bit



02

Khảo sát phần cứng

Bộ giải mã posit trên FPGA hoặc lõi RISC-V; thử generalized posit (sc, rs) ở 4–6 bit theo ALPS

ĐẠI HỌC BÁCH KHOA – ĐẠI HỌC ĐÀ NẴNG

Cảm ơn thầy và các bạn!

Nhóm sẵn sàng nhận câu hỏi

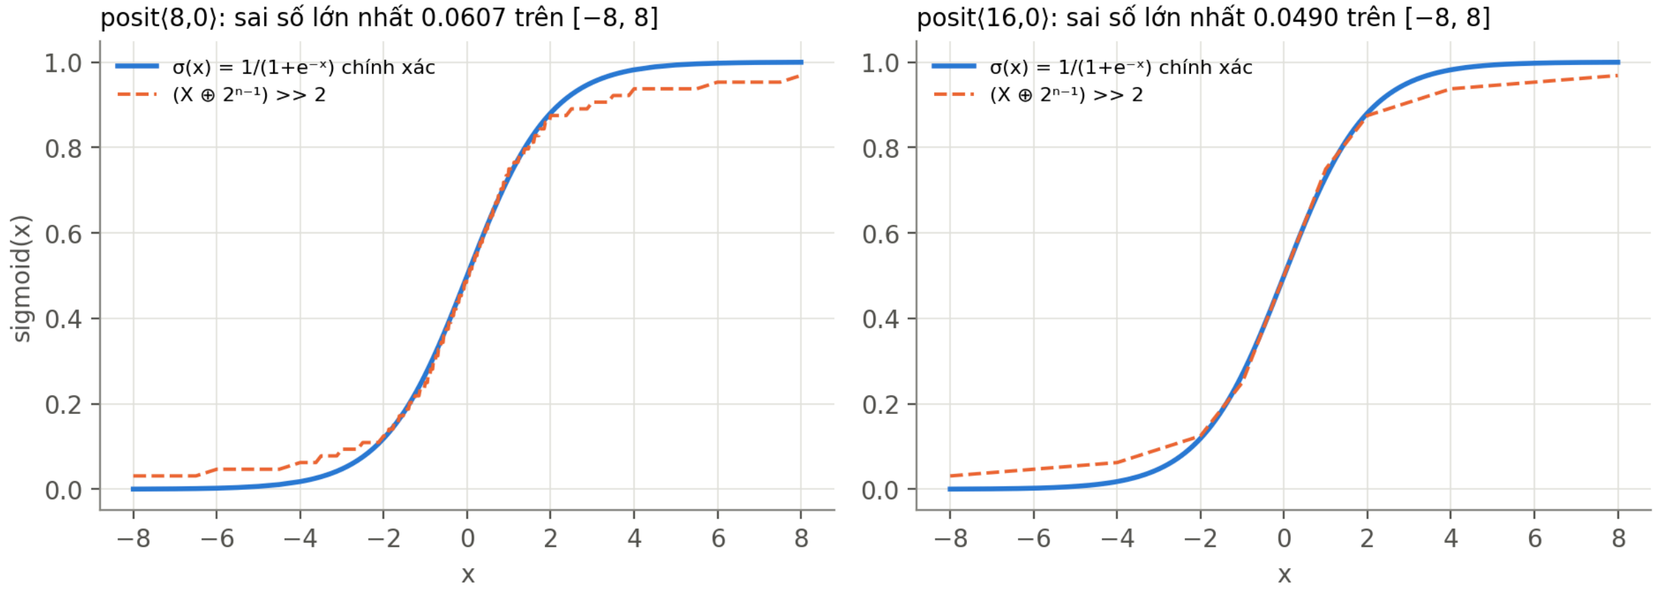
[Họ tên SV 1] · [Họ tên SV 2]

Đà Nẵng, 10/2026

DỰ PHÒNG · THÍ NGHIỆM E

Sigmoid bằng 2 phép toán bit

σ(x) ≈ (X XOR 2^{n-1}) >> 2 với posit es = 0 · sai số tối đa 0,061 (8-bit), 0,049 (16-bit) · tanh của [40]: 0,0980 → 0,0379 — **trùng bài báo**



Tài liệu tham khảo chính

[S1] Gustafson & Yonemoto — Supercomput. Front. Innov., 2017
[01] Langroudi et al. — EMC² 2018
[03] Carmichael et al., Deep Positron — DATE 2019
[04] Carmichael et al. — CoNGA 2019
[05] Murillo et al. — arXiv 2019
[06] Langroudi et al. — arXiv 2019
[07] Langroudi et al., Cheetah — arXiv 2019
[08] Lu et al. — SOCC 2019
[11] Raposo et al., PositNN — ICASSP 2021
[12] Langroudi et al., ALPS — CVPRW 2021
[18] Desrentes et al. (Kalray) — CoNGA 2022
[21] Cococcioni et al. — Neural Comput. Appl. 2021
[27] Nakahara et al. — IPSJ TSLDM 2022
[33] Langroudi et al., Adaptive Posit — CVPRW 2020
[35] Ramachandran et al., Log. Posit — DAC 2024
[36] Murillo et al., PLAM — IEEE TETC 2021
[40] Ho et al., Posit GAN — DATE 2021
[42] Wan et al. — Harvard, báo cáo môn học 2018
[43] Johnson (Facebook AI) — arXiv 2018
[44] Ciocirlan et al., POSAR — arXiv 2021
[46] Alouani et al. — VLSID 2021
[48] Kumar et al., SPADE — arXiv 2026 (preprint)

Mã [NN] = số đầu tên file trong thư mục papers_download · danh mục đầy đủ: báo cáo Word